



華東師範大學

EAST CHINA NORMAL UNIVERSITY

数据科学与工程算法基础

Algorithm Foundations of Data Science and Engineering

第八章 特征值计算

$$(1+x)^n = 1 + \frac{nx}{1!} + \frac{n(n-1)x^2}{2!} + \dots$$

课程提纲

Content

1 算法引入

2 幂法

3 瑞丽商迭代法

课程提纲


Content

1 算法引入


2 幂法

3 瑞丽商迭代法

PageRank 与特征值

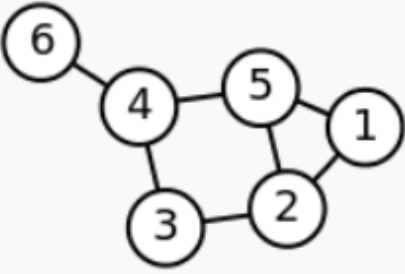


- 1: Set $\mathbf{r}^{(0)} = (\frac{1}{n}, \dots, \frac{1}{n})$;
- 2: For $k = 1, 2, \dots$;
- 3: Let $\mathbf{r}^{(k)} = \mathbf{r}^{(k-1)} \cdot M$;



- 一个概率转移矩阵为 P 的齐次有限随机游走的平稳分布为 π , 则满足 $\pi P = \pi$
 - π 为转移概率矩阵 P 最大特征值 1 对应的左特征向量
 - 如何有效计算随机游走的平稳分布?
 - 矩阵形式的 PageRank 算法为什么是正确的?

图的鲁棒性与特征值

Labeled graph	Degree matrix	Adjacency matrix	Laplacian matrix
	$\begin{pmatrix} 2 & 0 & 0 & 0 & 0 & 0 \\ 0 & 3 & 0 & 0 & 0 & 0 \\ 0 & 0 & 2 & 0 & 0 & 0 \\ 0 & 0 & 0 & 3 & 0 & 0 \\ 0 & 0 & 0 & 0 & 3 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 \end{pmatrix}$	$\begin{pmatrix} 0 & 1 & 0 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 & 1 & 1 \\ 1 & 1 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 \end{pmatrix}$	$\begin{pmatrix} 2 & -1 & 0 & 0 & -1 & 0 \\ -1 & 3 & -1 & 0 & -1 & 0 \\ 0 & -1 & 2 & -1 & 0 & 0 \\ 0 & 0 & -1 & 3 & -1 & -1 \\ -1 & -1 & 0 & -1 & 3 & 0 \\ 0 & 0 & 0 & -1 & 0 & 1 \end{pmatrix}$

- 图的拉普拉斯矩阵 $L = D - A$ ，其中 D 为对角的度矩阵， A 为邻接矩阵
- 图鲁棒性衡量了图结构受到攻击时保持结构的能力
 - 代数连通性：Laplacian 矩阵第二小特征值
 - 如何计算？

特征值与特征向量

- 对给定矩阵 $A \in \mathbb{R}^{n \times n}$ 和非零向量 v , 若 $Av = \lambda v$, 则 λ 是 A 的一个特征值, v 是 A 对应于特征值 λ 的特征向量
- 线性变换
 - 线性变换 = 拉伸 + 旋转
 - 矩阵 A 作用于向量 v 像是一个函数, 在 A 的作用下输入向量 v 变换为输出 λv
 - 也就是说, 矩阵 A 对其特征向量只进行拉伸
 - $Av = \lambda v$ 可以改写为 $Av - \lambda v = 0$ 或者 $(A - \lambda I)v = 0$
 - 齐次线性方程组具有非零解, 所以 $|A - \lambda I| = 0$

计算特征值和特征向量

- 给定矩阵 $A = \begin{pmatrix} 3 & -2 \\ 1 & 0 \end{pmatrix}$
- 特征方程为 $|A - \lambda I| = \lambda^2 - 3\lambda + 2 = 0$, 因此特征值为 $\lambda_1 = 1, \lambda_2 = 2$
- 通过解线性方程得到特征向量 $(A - \lambda_i I)v = 0$
 - 得对应于特征值 $\lambda_1 = 1$ 的特征向量为 $(1, 1)^\top$
 - 得对应于特征值 $\lambda_2 = 2$ 的特征向量为 $(2, 1)^\top$
- 但这种方法（高斯消元法）是不可扩展的，很难在大规模矩阵上使用

课程提纲

Content

1 算法引入

2 幂法

3 瑞丽商迭代法

幂法

- 设矩阵 A 有唯一的主特征值 λ_1 (模最大)
- 可以运用幂法求解主特征值及其特征向量

```
1:   Pick a starting vector  $\mathbf{x}^{(0)} \in \mathbb{R}^n$ , such that  $\|\mathbf{x}^{(0)}\| = 1$ ;  
2:   For  $k = 1, 2, \dots$ ;  
3:       Let  $\mathbf{v} = A\mathbf{x}^{(k-1)}$ ;  
4:       Let  $\mathbf{x}^{(k)} = \frac{\mathbf{v}}{\|\mathbf{v}\|}$ ;
```

- 幂法是一种迭代算法
 - 达到收敛条件算法终止
 - 向量单位化的目的为了防止计算溢出
 - 可以利用幂法求解随机游走的平稳分布
 - 为什么幂法是收敛的?

幂法分析

- 假设矩阵 A 标准化的特征向量构成一组标准正交基, 满足

$$v_i^\top v_j = \begin{cases} 1 & \text{if } i = j \\ 0 & \text{otherwise} \end{cases}$$

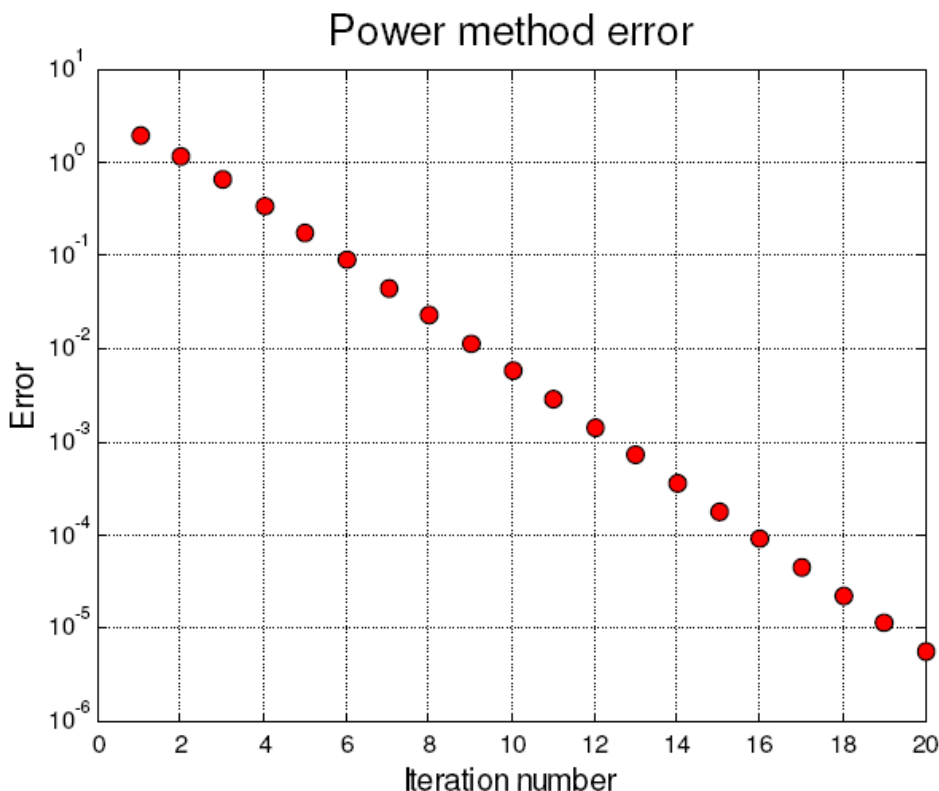
- 令 $x^{(0)}$ 为特征向量生成子空间中任意非零向量, 则

$$x^{(0)} = \sum_{i=1}^n c_i v_i \text{ 且 } c_1 \neq 0$$

- 则 $x^{(k)}$ 收敛到主特征向量 v_1 , 因为

$$\begin{aligned} \lim_{k \rightarrow \infty} A^k x^{(0)} &= \lim_{k \rightarrow \infty} \sum_{i=1}^n c_i A^k v_i = \lim_{k \rightarrow \infty} \sum_{i=1}^n c_i \lambda_i^k v_i \\ &= \lim_{k \rightarrow \infty} c_1 \lambda_1^k \left(v_1 + \sum_{i=1}^n \frac{c_i}{c_1} \left(\frac{\lambda_i}{\lambda_1} \right)^k v_i \right) = c_1 \lambda_1^k v_1 \end{aligned}$$

幂法分析 (续)



- 假设 $|\lambda_1| \geq |\lambda_2| \geq \dots \geq |\lambda_n|$
- 随着迭代次数的增加, 幂法收敛速度取决于 $\frac{\lambda_2}{\lambda_1}$, 即幂法是线性收敛的
- 如果主特征值具有重数 r , 计算得到的特征向量将是 r 个特征向量的线性组合

幂法扩展

- 反幂法

- 使用 A^{-1} 而不是 A , 因为 A^{-1} 的特征值是 $1/\lambda^i$
- 给出了一种求解矩阵绝对值最小的非零特征值的方法

- 平移法

- $A - \mu I$ 的特征值为 $\lambda_i - \mu$
- 运用幂法可以找到 $|\lambda_i - \mu|$ 最大的特征值
- 运用反幂法可以找到 $|1/(\lambda_i - \mu)|$ 最大的特征值, 即 A 最接近 μ 的特征值
- 因为无法事先知道 λ_i , 只能尝试不同的 μ
- 难以找到矩阵 A 所有的特征值

反幂法

- 直接计算 A^{-1} 复杂度高

- $A^{-1}x^{(k-1)} = v$ 等价于 $x^{(k-1)} = Av$
- 求解线性方程组方法多如逐次超松弛迭代法效率更高

- 1: Pick a starting vector $\mathbf{x}^{(0)} \in \mathbb{R}^n$, such that $\|\mathbf{x}^{(0)}\| = 1$;
- 2: For $k = 1, 2, \dots$;
- 3: Solve $A\mathbf{v} = \mathbf{x}^{(k-1)}$ for \mathbf{v} ;
- 4: Let $\mathbf{x}^{(k)} = \frac{\mathbf{v}}{\|\mathbf{v}\|}$;

- 其收敛性分析与幂法相同
- 对奇异矩阵，不能使用反幂法

平移法

- $A - \mu I$ 的特征值为 $\lambda_i - \mu$
- 给定 μ , 计算矩阵 A 最接近 μ 的特征值

- 1: Pick some μ close the desired eigenvalue;
- 2: Pick a starting vector $\mathbf{x}^{(0)} \in \mathbb{R}^n$, such that $\|\mathbf{x}^{(0)}\| = 1$;
- 3: For $k = 1, 2, \dots$;
- 4: Solve $(A - \mu I)\mathbf{v} = \mathbf{x}^{(k-1)}$ for \mathbf{v} ;
- 5: Let $\mathbf{x}^{(k)} = \frac{\mathbf{v}}{\|\mathbf{v}\|}$;

- 其收敛性与幂法相同
- 通过选择不同的 μ , 可以找到矩阵 A 更多的特征值
- 如何确定 μ ? (二分查找)

课程提纲

Content

1 算法引入

2 幂法

3 瑞丽商迭代法

牛顿迭代法


- 假设 r 是方程 $f(x) = 0$ 的一个解，如果 $f(x)$ 是一个可微函数，如何求它的解？
- 牛顿迭代法

- 1: Pick a starting point x_0 ;
- 2: Until the convergence condition;
- 3:
$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)};$$

- 假定真实解为 r ， $h = x_n - r$ 表明 x_n 距离真实解的距离
- 当 h 比较小时

$$0 = f(r) = f(x_n + h) \approx f(x_n) + hf'(x_n)$$

$$= f(x_n) + \frac{df(x)}{dx} \Big|_{x=x_n} \Delta(x_n)$$



瑞利商

- 瑞利商 (Rayleigh Quotient)

- 给定实对称矩阵 A , 其瑞利商为 $R_A(\cdot) : \mathbb{R}^n \setminus \{0\} \rightarrow \mathbb{R}$ 的函数

- 对 $\forall x \in \mathbb{R}^n \setminus \{0\}$, 其定义为 $R_A(x) = \frac{\langle Ax, x \rangle}{\langle x, x \rangle}$

- 矩阵 A 标准化的特征向量构成一组标准正交基, 满足

$$v_i^\top v_j = \begin{cases} 1 & \text{if } i = j \\ 0 & \text{otherwise} \end{cases}$$

- 因此

- $\langle x, x \rangle = x^\top x = \left(\sum_{i=1}^n c_i v_i \right)^\top \left(\sum_{i=1}^n c_i v_i \right) = \sum_{i=1}^n c_i^2$

- $\langle Ax, x \rangle = x^\top Ax = \left(\sum_{i=1}^n c_i v_i \right)^\top \left(\sum_{i=1}^n c_i A v_i \right) = \sum_{i=1}^n \lambda_i c_i^2$

瑞利商（续）

- 瑞利商改写为 $R_A(x) = \frac{\langle Ax, x \rangle}{\langle x, x \rangle} = \frac{\sum_{i=1}^n \lambda_i c_i^2}{\sum_{i=1}^n c_i^2}$
- 如果 $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n$, 则
 - $\lambda_1 = \max_{\mathbb{R}^n \setminus \{0\}} R_A(x)$
 - $\lambda_n = \min_{\mathbb{R}^n \setminus \{0\}} R_A(x)$
 - 对实矩阵 A , v_j 为特征值 λ_j 对应的特征向量, 则 $R_A(v_j) = \lambda_j$
 - 因此 $\lambda_1 \geq R_A(x) \geq \lambda_n$

瑞利商迭代法

- 在平移法中，放松固定平移值 μ 的假设
 - 每轮迭代中平移值随着迭代向量的变化而变化
 - 瑞利商迭代法

```
1:   Pick a starting vector  $\mathbf{x}^{(0)} \in \mathbb{R}^n$ , such that  $\|\mathbf{x}^{(0)}\| = 1$ ;  
2:   Let  $\lambda^{(0)} = r(\mathbf{x}^{(0)}) = (\mathbf{x}^{(0)})^T A \mathbf{x}^{(0)}$ ;  
3:   For  $k = 1, 2, \dots$ ;  
4:       Solve  $(A - \lambda^{(k-1)} I) \mathbf{v} = \mathbf{x}^{(k-1)}$  for  $\mathbf{v}$ ;  
5:       Let  $\mathbf{x}^{(k)} = \frac{\mathbf{v}}{\|\mathbf{v}\|}$ ;  
6:       Let  $\lambda^{(k)} = r(\mathbf{x}^{(k)}) = (\mathbf{x}^{(k)})^T A \mathbf{x}^{(k)}$ ;
```

- 当实矩阵 A 是对称矩阵时，瑞利商迭代法一定收敛
 - 瑞利商迭代法为什么收敛？
 - 收敛到什么？

瑞利商迭代法分析

- 定义函数 $f(v, \lambda) = Av - \lambda v$
- 计算函数 $f(v, \lambda)$ 的全微分 $(\Delta z = \frac{\partial z}{\partial x} \Delta x + \frac{\partial z}{\partial y} \Delta y)$, 得到
$$\Delta f(v, \lambda) = (A - \lambda I) \Delta v - (\Delta \lambda) v$$
- 牛顿迭代法第 $k + 1$ 轮给出的近似解可以计算为
$$\begin{aligned} 0 &= f(v_k, \lambda_k) + \Delta f(v_k, \lambda_k) \\ &= (A - \lambda_k I)(v_k + \Delta v_k) - (\Delta \lambda_k) v_k \\ &= (A - \lambda_k I) v_{k+1} - (\Delta \lambda_k) v_k \end{aligned}$$
- 因此, $v_{k+1} = (\Delta \lambda_k)(A - \lambda_k I)^{-1} v_k$


瑞利商迭代法收敛性分析

- 为简单起见，仅考虑两个最大的主特征值

$$\begin{aligned} R_A(x^{(k)}) &\approx \frac{(c_1\lambda_1^k v_1 + c_2\lambda_2^k v_2)^\top (c_1\lambda_1^{k+1} v_1 + c_2\lambda_2^{k+1} v_2)}{(c_1\lambda_1^k v_1 + c_2\lambda_2^k v_2)^\top (c_1\lambda_1^k v_1 + c_2\lambda_2^k v_2)} \\ &= \frac{c_1^2 \lambda_1^{2k+1} + c_2^2 \lambda_2^{2k+1}}{c_1^2 \lambda_1^{2k} + c_2^2 \lambda_2^{2k}} = \lambda_1 + O\left(\left(\frac{\lambda_2}{\lambda_1}\right)^{2k}\right) \end{aligned}$$

- 瑞利商迭代法是收敛的，其极限为最大主特征值 λ_1
- 随着迭代次数的增加，瑞利商收敛速度取决于 $\left(\frac{\lambda_2}{\lambda_1}\right)^2$

瑞利商迭代法 VS 幂法



降阶技术

- 矩阵 A 标准化的特征向量构成一组标准正交基，满足 $v_i^\top v_j = \begin{cases} 1 & \text{if } i = j \\ 0 & \text{otherwise} \end{cases}$
- 通过正交分解可得 $A = \sum_{i=1}^n \lambda_i v_i v_i^\top$
 - 求得主特征值 λ_1 后，构造矩阵 $A^{(1)} = \sum_{i=2}^n \lambda_i v_i v_i^\top$
 - 因为 $A^{(1)} = \sum_{i=2}^n \lambda_i v_i v_i^\top = A - \lambda_1 v_1 v_1^\top$
 - 计算 $A^{(1)} v_i = \begin{cases} 0 & \text{if } i = 1 \\ \lambda_i v_i & \text{otherwise} \end{cases}$

降阶技术（续）

- 通过降阶技术，把原矩阵的特征值变为 $0, \lambda_2, \dots, \lambda_n$ ，且满足 $|\lambda_2| \geq \dots \geq |\lambda_n| \geq 0$
- 运用幂法或者瑞利商迭代法可以进一步求解矩阵 $A^{(1)}$ 的主特征值
- 依次迭代，定义矩阵 $A^{(k+1)} = A^{(k)} - \lambda_k v_k v_k^T$ ，求得后续特征值和特征向量

本章小结

- 特征值计算方法
 - 幂法
 - 反幂法
 - 瑞利商迭代法
 - 降阶方法
- 特征值与特征向量的应用场景
 - 图中顶点 PageRank 值
 - 图鲁棒性度量
 - 特征提取
 - 数据降维